

R2 — Apresentação executiva

Diversidade, qualidade e ampliação da base do gerador offline de questões (SAEB)

Relatório de execução dos dias 1 e 2 de outubro de 2026

Qwen3-1.7B + QLoRA + GGUF — geração offline no aplicativo

2 de outubro de 2026

- ✔ **Modelo promovido** em todos os 8 gates bloqueantes (456 questões por modelo, 96 pares prompt×semente).
- ✔ **Diversidade comprovada:** lotes de 10 questões sem repetição e com 10 contextos distintos.
- ⚠ **Teste real do 9º H17 expôs o ponto fraco:** só 5 de 20 questões corretas — o gate não enxergava erro conceitual.
- 🔧 **Resposta:** verificador de geometria, validador, revisor, árbitro e 2º revisor de outra família, com decisões humanas na base.
- ✔ **Escala concluída:** base auditada por inteiro e ampliada de 1.435 para **2.607** exemplos (meta 2.370).

8/8 gates
bloqueantes aprovados

0,773 → 0,797
diversity_score


1.435 → 2.607
exemplos na base (+1.234 novos)

déficit 1.386 → 274
em relação à meta de 2.370

O modelo atingiu diversidade: números do gate decisório

Métrica	Antigo	Novo
<i>diversity_score</i>	0,773	0,797
Cobertura de subtemas	0,716	0,778
Duplicatas semânticas	0,0028	0,000
Aderência à habilidade	75,5%	82,4%
Depende de figura ausente	2,4%	0,2%
Tempo por questão (CPU)	14,4 s	16,4 s

456 questões por modelo; mesmas sementes e prompts
(comparação pareada); modo planejado, sem regenerações.



Exemplo: um lote de 10 questões (9º ano, H17, Fácil)

Plano de cobertura do lote R2 de outputs/testes_locais: cada questão recebeu subtema, raciocínio e contexto *diferentes*.

#	Subtema	Raciocínio	Contexto	Correta?
1	triângulo	lados	festa junina	✓
2	quadrilátero	ângulos	loja	✗
3	triângulo	ângulos	coleção	✗
4	quadrilátero	lados	horta	✗
5	triângulo	lados	biblioteca	✓
6	quadrilátero	ângulos	esporte	✗
7	triângulo	ângulos	reciclagem	✗
8	quadrilátero	lados	mesada	✗
9	triângulo	lados	feira	✓
10	quadrilátero	ângulos	culinária	✗

Leitura: diversidade de contexto e de subtema = 100% (coberta). A coluna da direita mostra por que diversidade *não* basta: o plano pedia combinações que o currículo não ensina (quadrilátero por ângulos), e a correção da matemática precisava de um verificador próprio.

Exemplos de questões geradas e aprovadas na auditoria

9º ano H17 — festa junina (correta)

Em uma festa junina, as barracas formam triângulos. A barraca A tem todos os ângulos agudos, a B tem um ângulo obtuso e a C tem um ângulo reto. Como os triângulos podem ser classificados quanto aos ângulos?

D) A é agudo, B é obtusângulo e C é retângulo. **Gabarito: D**

9º ano H17 — sem contexto (correta)

Triângulo ABC tem lados $AB = 5$ cm, $BC = 5$ cm e $CA = 6$ cm. Qual é o tipo de triângulo?

B) Isósceles. **Gabarito: B**

Resolução: dois lados iguais ($AB = BC = 5$ cm).

9º ano H17 — barraca na festa junina (correta)

Na festa junina, os organizadores decoraram uma barraca triangular com lados de 8 m, 10 m e 12 m. Como os lados são diferentes entre si, qual é o tipo de triângulo?

E) Escaleno. **Gabarito: E**

9º ano H17 — prateleiras da biblioteca (correta)

Na biblioteca da escola há prateleiras em forma de triângulo. Um deles tem todos os lados iguais. Como se chama esse tipo de triângulo?

D) Equilátero. **Gabarito: D**

Exemplos tirados de outputs/testes_locais; confirmados na auditoria matemática (Log.txt). A diversidade vem do plano, a correção vem da verificação.

O lado B: o teste local revelou erros que o gate não media

Dois lotes de 10 questões (9^o H17, Fácil, 125 s–159 s por lote) foram auditados questão a questão: **5 corretas e 15 com defeito.**

Classe de erro (exemplo)	Qtd.
Premissa impossível (triângulo com dois ângulos retos)	4
Gabarito errado (4 ângulos retos $\Rightarrow$ “quadrado”; 5, 7, 9 “acutângulo”)	4
Mais de uma resposta correta (90–45–45 é retângulo e isósceles)	3
Dados ausentes (“um ônibus passa por 4 pontos”)	4
Corretas e únicas	5


Causa central: o modelo infere “tem uma propriedade de $X \Rightarrow$ é X ”, ignorando a hierarquia (quadrado $\subset$ retângulo) e que lados e ângulos são eixos distintos.

Por que o gate não viu: o verificador só conferia contas; em 9^o H17, 283 de 311 questões eram “não verificáveis”.

Cenário da base: antes e depois da escala

Ano	Hab.	Antes	Depois	Meta	Déficit
1º	3	203	231	90	1
2º	24	419	811	720	79
3º	3	166	192	90	0
4º	1	58	59	30	0
5º	22	249	622	660	89
9º	26	351	705	780	105
Total	79	1.446	2.620	2.370	274

Questões efetivas (sem inconsistentes nem quase-duplicatas). Déficit: de 1.386 para 274; habilidades abaixo da meta: de 76 para 56 (de 79). Meta: mínimo de 30 por habilidade, 3 por subtema e 3 dificuldades equilibradas.



Por que estamos aumentando (e curando) a base

 **76 das 79 habilidades abaixo da meta;** mediana de apenas 11 exemplos por habilidade.

 **9º H17 tinha 7 exemplos** — a causa raiz dos erros do teste local.

 **37 habilidades sem gabarito verificável** automaticamente (geometria, medidas, leitura de dados).

 Letra E é o gabarito em só 3% dos itens; 24 habilidades com subtemas vazios.

 **17 itens reais corrompidos pela planilha:** frações viraram datas (“3/6” → “2025-06-03”). 15 restaurados, 2 removidos por ambiguidade.

 **19 removidos** por decisão humana (erro matemático, resposta não única ou dados insuficientes).

 **Validação também afetada:** 4 de 30 itens quebrados em `val.jsonl` — as métricas devem descontá-los.

 Objetivo: **quantidade, qualidade e diversidade** juntas, não só volume.

Estratégia em curso: quatro frentes



1. Inferência segura

plano de subtemas, guardas, permutação do gabarito e verificador de geometria



2. Plano corrigido

combinações subtema $\times$ raciocínio válidas; pergunta nomeia o eixo



3. Base ampliada e curada

injeção por habilidade com dois juízes; auditoria de tudo o que já existe



4. Decisão humana no centro

remover, manter ou editar item; prece-dência sobre as regras automáticas

Verificador de geometria

aprova 5/5 corretas e reprova 15/15 erradas do teste local; 0 reprovações em 9.294 questões do treino/validação.

Plano corrigido


quadrilátero pedido pelas propriedades combinadas, como nos itens reais; mudou só 7 das 79 habilidades.

Gates de promoção aprovados (rodada decisória, 32 prompts)

Gate	Critério	Antigo	Novo	Status
P1	JSON válido	100%	100%	✓
P2	Quantidade entregue	100%	100%	✓
P3	Gabarito inconsistente ($\leq$ base+1 pp e $\leq 2\%$)	0,0%	0,0%	✓
P4	Aderência à habilidade	75,5%	82,4%	✓
P5	Depende de figura ausente	2,4%	0,2%	✓
P6	Dificuldade correta	100%	100%	✓
P7	Sem esquecimento no 5º/9º ano	—	preservado	✓
P8	Tempo por questão ($\leq$ base+20%) (informativo)	14,4 s	16,4 s	✓
G11	Diversidade sem perda de qualidade	0,773	0,797	✓

Limite honesto: o 0% de inconsistência vale para as **40%** das questões com conta verificável. As outras 60% são conceituais; por isso o gate sozinho não garante correção — daí o verificador de geometria e os agentes das próximas telas. O tempo foi medido no PC, não no celular.

Estratégia de validação: duas camadas de juízes e um árbitro



Filtros	schema, consistência de contas, dados ausentes, figura, duplicata (texto e <i>dados+resposta</i>), verificador de geometria, contexto inverossímil.
Árbitro (Gemini)	outra família de modelo: resolve às cegas <i>antes</i> de qualquer remoção automática por erro matemático.

Papéis do validador e do revisor

	Validador (rigor matemático)	Revisor (SAEB e pedagogia)
Recebe	enunciado e alternativas permutadas; sem gabarito, resolução ou dificuldade	enunciado e alternativas em outra permutação; sem gabarito nem resolução do autor
Faz	resolve passo a passo; só depois compara com o gabarito	resolve de forma própria; checa habilidade, ano, distratores, clareza e contexto
Veta	premissa impossível, dados insuficientes, resposta não única, alternativas equivalentes	distrator verdadeiro, contexto forçado, conteúdo de outro ano

2º revisor (Gemini, opcional): mesmo prompt do revisor, outra família de modelo, permutação própria; só é chamado se os dois primeiros aprovam. Se ficar sem cota ou cair, o fluxo segue sem ele e marca a questão.

Regras decididas

- Distrator deve ser **estritamente falso**, por qualquer critério.
- Duas casas decimais bastam quando o valor é dízima ($5/11 \approx 0,45$).
- Questão matematicamente errada **sai** da base.
- Resolução vazia: cadastrar a resolução comentada.

Por que o árbitro

Os dois juízes são do mesmo modelo e **erram juntos**: ambos contaram “terça + 10 dias = sexta” (o certo é quinta) e marcaram a questão como errada. Uma terceira opinião, de família diferente, evita remover questão correta.

Calibração dos juízes: o que foi medido


Teste	Resultado	Observação
20 questões auditadas do 9º H17 (par validador+revisor)	15/15 ruins reprovadas; 5/5 boas aprovadas	ajustado nesses casos (<i>in-sample</i>)
Itens reais do banco: falsa rejeição	0/45 (após remover defeitos reais)	5 “rejeições” eram erros do banco
Defeitos conhecidos da auditoria	4/4 reprovados pelo par	revisor sozinho: 2/4
Distrator verdadeiro por outro eixo (12 casos)	6/6 reprovadas; 6/6 controles aprovados	—
Concordância validador $\times$ revisor (κ)	0,79	0,20 na auditoria da amostra de 59
2º revisor Gemini (20 auditadas)	4/4 boas aprovadas; 16/16 erradas reprovadas	11/12 em aceitas novas (fora do ajuste)

Dificuldade: comparado ao rótulo do banco (45 itens), o revisor concordou pouco (κ ponderado = 0,09) e *rebaixaria* 80% dos itens Moderado/Difícil. O banco rotula dificuldade *relativa à habilidade*, a rubrica do revisor é absoluta. Critério fixado antes de olhar os dados: >10% de rebaixamento $\Rightarrow$ **rebaixamento automático suspenso**.

Escala concluída: o que foi gerado e auditado

Indicador	Valor
Questões novas aceitas	1.234
2º / 5º / 9º ano	408 / 383 / 385
1º / 3º / 4º ano	29 / 27 / 2
Taxa de aceitação (aceitas/candidatas)	≈52%
Itens da base auditados	1.435
Chamadas Maritaca (auditoria + injeção)	≈10,6 mil
Árbitro Gemini: remoções confirmadas	43 de 48
Base final (train_curado_v3)	2.607

Gasto abaixo da projeção (13,6 mil chamadas, ≈29 h). Dois processos em paralelo, com teto de chamadas por etapa.



Auditoria e limpeza da base existente

Confiança nos 1.435 itens auditados


Nível	Itens	%
Alta	1.237	86%
Média	65	5%
Baixa	123	9%
Não avaliados	10	1%

Nos itens reais, 81 saíram com confiança baixa; nenhum é removido sozinho por isso: vão para revisão humana (132 itens).

O que mudou na base

Ação	Itens
Removidos por decisão humana	19
Removidos por erro matemático (com árbitro)	43
Restaurados (fração virou data)	15
Resolução comentada cadastrada	1
Em revisão humana	132

Onde queremos chegar



Base	de 1.435 para 2.607 exemplos (feito); falta fechar 274 do déficit, com mínimo de 30 por habilidade e 3 dificuldades equilibradas; zero questão com erro conhecido.
Qualidade	verificação da correção em <i>todas</i> as habilidades, não só nas de conta; o gate passa a medir também o que hoje é "não verificável".
Produto	questões diversas, corretas e com resposta única, geradas offline em 2–3 min por lote de 10, com fallback ao modelo anterior se os reportes passarem de 2%.

Riscos conhecidos

- ⚠ Juízes do mesmo modelo erram juntos; o árbitro Gemini atua só na remoção e o 2º revisor Gemini ainda não foi aplicado às 1.234 aceitas.
- ⚠ Verificador de geometria cobre 9º H16/H17 e se abstém em cerca de 40% das questões de H17.
- ⚠ Os números de calibração foram ajustados nos mesmos casos (*in-sample*); falta conjunto cego.
- ⚠ Tempo medido no PC, ainda não no celular.
- ⚠ Um erro de código (resposta nula) interrompeu a injeção do 2º ano; corrigido e retomada.

Próximos passos

- ✓ Conferir amostra das 43 remoções automáticas e os 132 itens em revisão humana.
- ✓ Decidir sobre rejulgar as 1.234 aceitas com o 2º revisor Gemini ($\approx 14\%$ de reprovação).
- ✓ Auditoria humana cega de 30–40 questões novas de H17 antes de ligar o verificador em modo ativo.
- ✓ Retreino e novo gate com baseline regenerado.
- ✓ Guia de portabilidade para o React Native.