R3. Reunião de acompanhamento

Ciclo v8 do Qwen3-4B: base de dados, juízes, gate e expectativa para o aplicativo

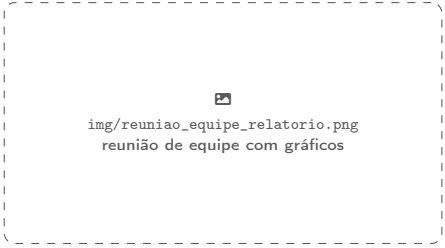
Relatório de execução de 19 a 23 de outubro de 2026

Qwen3-4B + QLoRA + GGUF, geração offline de questões SAEB de Matemática

23 de outubro de 2026

Roteiro

1. Resumo executivo
2. Ponto de partida: o que o professor mediu
3. Como decidimos o caminho
4. Melhorias na base de dados
5. Juízes automáticos calibrados
6. Resultados: juízes pareados e gate
7. Comparação com os modelos anteriores
8. Professor no v8rftb e auditoria dos extras
9. Gerar e conferir: o modelo confere a própria questão
10. Expectativa para o aplicativo
11. Riscos e próximos passos



Resumo executivo

Base

2.918 questões com a resolução antes das alternativas, mais 875 aprovadas por juiz. Total de 3.793, com gabarito em 20% por letra.

Juízes

Jev: 64,6% $\rightarrow$ **73,4%** (800 pares, $p < 0{,}001$). Maritaca: 60,2% $\rightarrow$ 66,5% (400 pares, $p = 0{,}065$).

Gate

v8rftb contra v7b: **PROMOVIDO**. Consistência sobe de 93,6% para 100% e as falhas caem de 3 para 1 em 90.

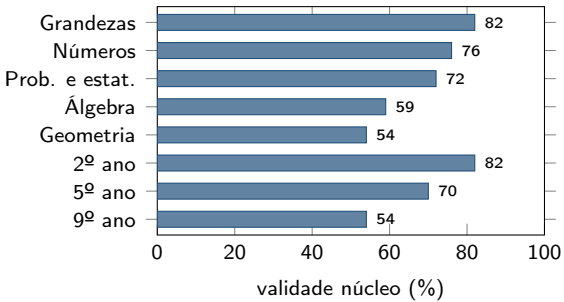
O professor não confirmou o ganho: núcleo de **65,4%** (51 de 78, IC95 [54,3; 75,0]) contra 68,9% do v7b, dentro do ruído e abaixo da meta de 80%. **Não publicar o v8rftb.** Os extras do treino têm 88% de núcleo, então o limite está na geração.

Nova alavanca, sem API: o 4B base resolve a questão às cegas e ela só vale se chegar ao mesmo gabarito. Na versão crítica, que julga cada alternativa e os dados, o núcleo do v8rftb vai a **85,2%** perdendo 10% das válidas. O custo é de cerca de 50 s por questão no PC.

Ponto de partida: 222 questões do 4B v7b avaliadas pelo professor

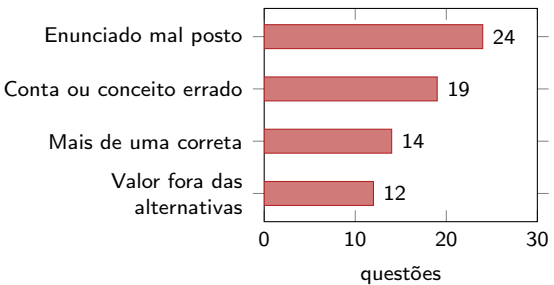
O professor avaliou às cegas 222 questões do melhor modelo da época (Qwen3-4B v7b). A questão é válida no critério **núcleo** quando a matemática está correta, só uma alternativa responde e os dados bastam.

- Núcleo: **68,9%**, IC95 [62,5; 74,6]
- A base de treino tem 97,9% de núcleo. O gargalo é o modelo, não os dados.
- Hiperparâmetros não mostraram efeito acima do ruído entre seeds.



9º ano e Geometria concentram as falhas (54% cada).

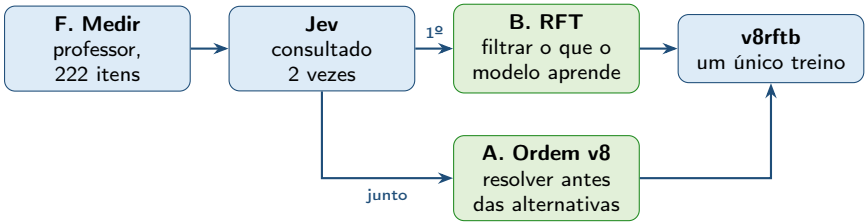
Por que as 69 questões falharam



A causa mais comum é o enunciado mal posto, com dados contraditórios ou inventados. Depois vêm a conta errada e a resposta duplicada.

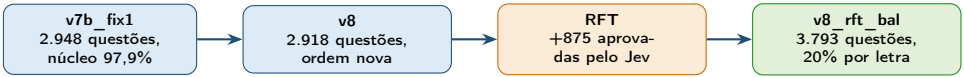
Reordenar o JSON resolve só a barra "valor fora das alternativas", que vale cerca de **5 pontos**. Para as outras três, era preciso filtrar o que o modelo aprende. Daí veio o RFT (*Rejection Fine-Tuning*, ou ajuste fino por rejeição): o modelo gera várias questões, um juiz descarta as ruins e o modelo é treinado de novo só com as aprovadas.

Como decidimos o caminho



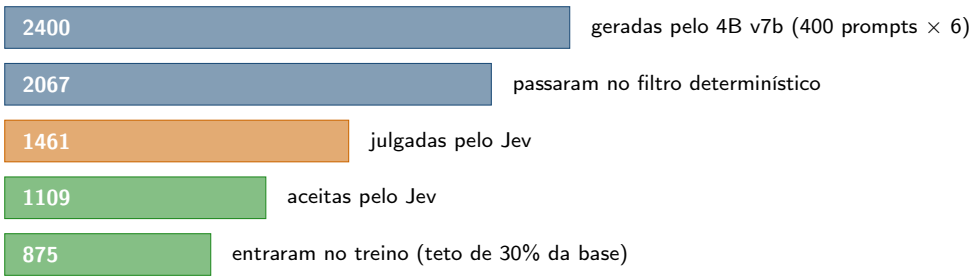
Consulta	Resultado
1ª, antes da medição	A primeiro (probabilidade média 0,76). A medição F era pré-requisito (0,94).
2ª, com a medição	B primeiro nas 4 ordens testadas (B 0,67 contra A 0,30). A e B se complementam.
Hiperparâmetros	Sem evidência de ganho acima do ruído entre seeds (0,05). Ficaram de fora.

Melhorias na base de dados



Mudança	Por que importa
Resolução antes das alternativas	O valor calculado já existe quando o modelo escreve as opções.
Uma questão por exemplo (47 divididos)	É o formato real do aplicativo, que pede uma questão por chamada.
Resolução sem citar "alternativa B"	As alternativas ainda não existem nessa ordem. Isso também permite embaralhar as opções no app.
Trava do verificador	Se a limpeza mudasse o veredito, a questão saía. Saíram 30 injetadas e nenhum item real do banco.
Extras com letras permutadas	Os extras chegaram com 34,5% de gabarito A. A permutação corrige para 20% cada.

RFT (ajuste fino por rejeição): o modelo gera, o juiz filtra, o modelo reaprende



- 606 amostras ficaram sem julgamento quando o crédito do OpenRouter acabou. Mesmo assim, as 79 habilidades receberam extras.
- Também saíram 282 pares bom/ruim, guardados para um treino ORPO futuro.

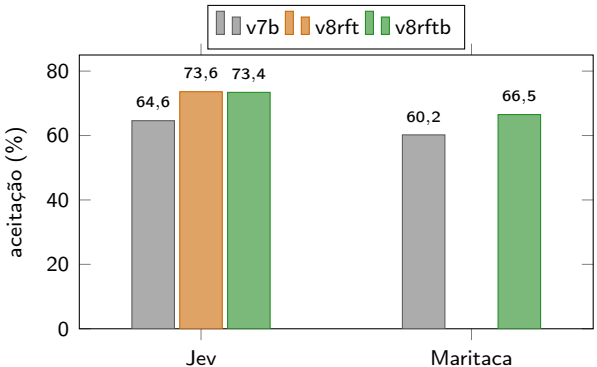
Dois juízes calibrados contra o professor

Antes de usar um juiz para decidir, conferimos se ele concorda com o professor nas mesmas 222 questões.

	Jev (TypeSafe)	**Maritaca** (sabiá-4)
Concordância com o professor (κ)	**0,795**	0,725
Inválidos que o juiz pega (recall)	81,2%	**90,9%**
Válidos que o juiz perde	**3,9%**	13,7%
Válidos entre os aceitos	91,9%	**95,7%**
Custo da calibração	US$ 0,01	R$ 5,36
Papel neste ciclo	filtro do RFT e 1º juiz	2º juiz, independente do filtro

A meta era $\kappa \geq 0{,}6$, e os dois passaram. A Maritaca é mais rígida e não participou do filtro de treino, então ela confirma o ganho sem viés de construção. Os dois rodam por API, por isso servem para medir e filtrar dados, mas não vão para o celular.

Resultados: os mesmos prompts e seeds nos dois modelos



Pareado	Jev	Maritaca
Pares	800	400
Só o v7b aceita	110	72
Só o v8rftb aceita	**180**	**97**
McNemar p	$< 0{,}001$	0,065

O balanceamento não custou qualidade, porque o v8rft e o v8rftb ficam empatados no Jev. No 9º ano, a aceitação do Jev sobe de 55% para 68%.

Gate mecânico: v8rftb contra v7b (3 rodadas, 90 pares)

Gate	O que verifica	v7b	v8rftb	
G1*	Estrutura do JSON nas questões entregues	100%	100% (n=89)	✅
G2*	Falhas depois das tentativas (teto 5%)	3/90	**1/90**	✅
G3*	Gabarito consistente com a conta	93,6%	**100%**	✅
G4	Dependência de figura	0	0	✅
G6*	Letra mais frequente (limite: base + 5 pontos)	40,0%	41,1%	✅
G7*	Sem esquecimento no 5º e 9º anos	100%	100%	✅
G5	Dificuldade (informativo)	100%	100%	✅
G8	Velocidade (informativo)	13,8 tok/s	15,0 tok/s	✅

Veredito: PROMOVIDO. O gate garante que nada piorou, mas não mede se a matemática está certa. Quem mede isso é o professor.

Mudanças nas regras do gate, com transparência

Data	Mudança e motivo	Tipo
22/10	G5 e G8 viram informativos e G9 sai. G5 só copiava o rótulo pedido (100% nos dois lados). G8 reprovou 6 de 18 vereditos por tamanho do modelo ou aquecimento da GPU.	Decisão do responsável, antes de medir o candidato
23/10	O G1* passa a contar só as questões entregues. O único item reprovado tinha B igual a D, mas já tinha sido descartado como falha e contado no G2*. Com 90 pares, o limite de 99% virava tolerância zero.	Revisão depois de uma reprovação, documentada no código

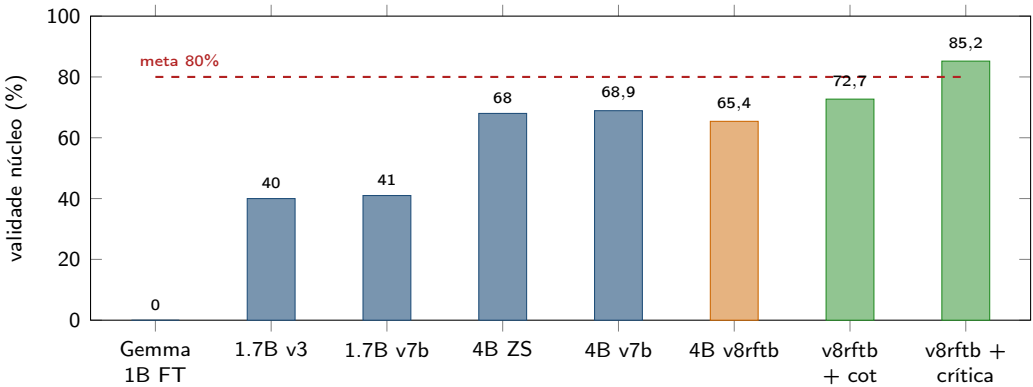
- Uma questão entregue com estrutura ruim continua reprovando. Três testes novos garantem isso.
- Com `-gates-completos`, a regra antiga volta e o veredito antigo (NÃO PROMOVIDO) se reproduz.
- O veredito reprovado ficou guardado como evidência.

Comparação com os modelos anteriores

Modelo	Tamanho	Núcleo (professor)	Gate	Melhor contribuição
Gemma 3 1B zero-shot	0,8 GB	15% (n=20)	base	Pipeline Gemma pronto e trava que impede comparar famílias diferentes
Gemma 3 1B fine-tune	0,8 GB	0% (n=20)	✗ 3 seeds	Mostrou que 1B não comporta a tarefa
Qwen3-1.7B v3 (baseline_v1)	1,1 GB	40% (n=40)	✓	Primeiro modelo publicado, gramática GBNF e gate multiseed
Qwen3-1.7B v6	1,1 GB	n/d[a]	✓	Mostrou que passar no gate não garante qualidade, e a amostra humana passou a decidir
Qwen3-1.7B v7b	1,1 GB	41% (n=80)	✓	Base com 97,9% de núcleo, o que mostrou que o gargalo é o modelo
Qwen3-4B zero-shot	2,5 GB	68% (n=40)	base	Teste de teto: o tamanho do modelo pesa mais que a curadoria
Qwen3-4B v7b	2,5 GB	**68,9%** (n=222)	✓	Primeira medida confiável, taxonomia de falhas e calibração dos juízes
Qwen3-4B v8rftb	2,5 GB	65,4% (n=78)	✓	Gate e juízes melhoraram, mas o professor não viu ganho. Com dados bons (88%), o limite é a geração

Núcleo somado das amostras cegas de cada modelo. O 1.7B v7b variou de 25% a 55% entre quatro amostras de 20, e o baseline_v1 deu 25% e 55%. [a] As folhas do v6 não tinham as colunas do núcleo. Na validade geral (7 dimensões), o v6 deu 35% e o baseline_v1 50%. Tamanho do 4B fine-tunado: GGUF Q4_K_M de 2,5 GB mais adaptador LoRA de 66 MB.

A evolução em um gráfico



Núcleo medido pelo professor (n=20 a 80 nos modelos pequenos, 222 no 4B v7b e 78 no v8rftb). As barras verdes são as questões do v8rftb que passaram na conferência (66 na cot e 54 na crítica). Só a crítica passa da meta de 80%, ainda com IC95 [73; 92].

Professor no v8rftb: 78 questões às cegas

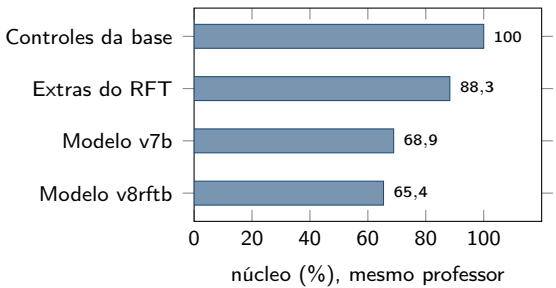
Recorte	Núcleo	n
Geral	**65,4%**	78
2º ano	83%	23
5º ano	59%	22
9º ano	**50%**	26
Números	67%	33
Geometria	62%	13
Grandezas e medidas	69%	13
Prob. e estatística	70%	10
Álgebra	56%	9
Verificador ok	79%	42
Verificador não verificável	50%	36

Causas das 27 reprovadas, item a item, pelo comentário do professor:

- 9 com situação mal definida ou dado que falta,
- 7 com conta ou resolução errada,
- 6 com mais de uma alternativa correta e
- 5 com dados que se contradizem no enunciado.

O 9º ano segue como o ponto fraco. Por unidade, nenhuma se destaca, porque cada uma tem só 9 a 33 questões. **Nenhuma das anteriores** não pesou (59% contra 68%, dentro do ruído). O filtro determinístico atual só marca o que não consegue verificar, então não separa bem.

Auditoria dos extras do RFT: os dados de treino são bons

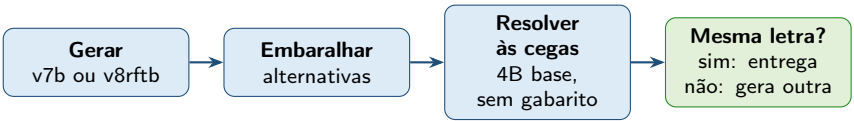


Folha cega com 60 extras que o Jev aprovou e 20 questões da base, misturados.

- Extras: **53/60 = 88,3%**, IC95 [77,8; 94,2]
- Controles: 20/20 = 100% (Fisher $p = 0{,}18$)
- Extras contra o v8rftb: $p = 0{,}0025$

O modelo treinou com dados de 88% a 100% de núcleo e mesmo assim gera 65%. Melhorar só os dados não basta. O limite está na geração.

Gerar e conferir: o modelo confere a própria questão



	350 questões já rotuladas		78 questões do v8rftb	
Regra	Mantidas	Núcleo	Mantidas	Núcleo
Sem filtro	350	65,4%	78	65,4%
Só a letra, sem raciocínio	44%	74,0%	–	–
Raciocínio curto (cot)	**74%**	**82,7%**	**85%**	**72,7%** [61; 82]
Verificador ok	45%	82,9%	54%	78,6%
cot e verificador ok	39%	91,2%	47%	83,8% [69; 92]

A conferência perde só 6% das questões válidas. Sem raciocínio, o resolvedor acerta metade das válidas e não serve. No PC, cada conferência leva cerca de 11,5 s. As 350 questões misturam a base (96% válida), por isso o número é mais alto ali.

Modo crítica: julgar cada alternativa e os dados

Regra (78 do v8rftb)	Mantidas	Núcleo	Perde
Sem filtro	78	65,4%	–
cot	66	72,7%	6%
Crítica	**54**	**85,2%**	**10%**
Crítica, sem 5 do ajuste	51	84,3%	10%
cot e crítica	51	88,2%	12%
Crítica e ok	31	96,8%	–

O 4B base resolve, julga cada alternativa e diz se há contradição ou dado faltando. Só passa com uma única correta, igual ao gabarito. A primeira versão do prompt chutava sem fazer conta e foi trocada depois de 5 questões.

Ainda passam 8 inválidas:

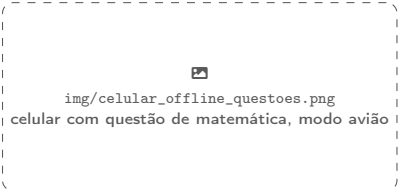
- 5 com ambiguidade que o modelo não percebe (losango, 1,4 igual a 1,40, variável não definida) e
- 3 com **resolução errada**. A crítica não lê a resolução.

Cautela: o IC95 vai de 73% a 92%, e o método foi desenhado olhando os erros destas mesmas 78 questões. Falta validar em questões novas.

Expectativa para o aplicativo mobile

Item	Qwen3-1.7B (hoje)	Qwen3-4B v8rftb
Arquivo do modelo	1,1 GB	2,5 GB + 66 MB
Memória estimada[b]	cerca de 1,4 GB	cerca de 3 GB
Velocidade (CPU do PC)	27 tok/s	15 tok/s
Tempo por questão (PC)	cerca de 8 s	cerca de 21 s
Núcleo (professor)	cerca de 40% (n=80)	65% (n=78)
Com crítica[c]	–	85%, cerca de 105 s
Gramática enviada	`questao.gbnf`	`questao_v8.gbnf`

[b] Pesos mais o cache de 2.048 tokens (cerca de 0,3 GB no 4B). Estimativa de cálculo, ainda sem medida no aparelho. [c] Gerar (21 s), criticar (cerca de 50 s) e gerar de novo nos 31% descartados. Estimativa feita no PC.

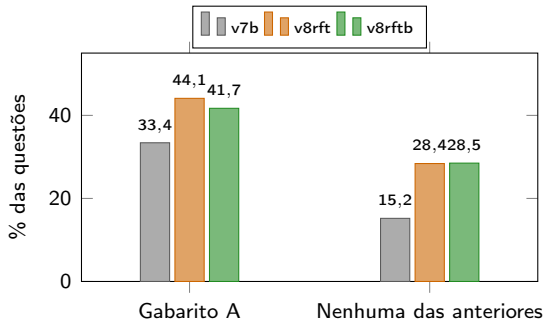


O que esperar: correção parecida com a do v7b (65 a 69%), bem acima do 1.7B, ao custo de cerca de 2,7 vezes mais tempo por questão e 2 vezes mais memória. Com a crítica, o núcleo vai a cerca de 85%, mas cada questão entregue leva cerca de 5 vezes mais no PC. Gerar em segundo plano, antes de o aluno pedir, pode esconder essa espera. Pela estimativa, o 4B pede aparelhos com 6 GB de RAM ou mais. Em celulares, a velocidade deve ficar abaixo da do PC. Por isso é preciso medir em um aparelho real antes de publicar.

O que muda na integração com o app

1. **Trocar a gramática junto com o modelo.** O v8 só funciona com `questao_v8.gbnf`, que o app envia inline. As chaves do JSON continuam as mesmas, então a leitura por nome de chave não muda.
2. **Embaralhar as alternativas no app.** A resolução do v8 não cita letras, então o app pode sortear a ordem das opções e remapear o gabarito. Assim o viés de letra deixa de importar para o aluno.
3. **Descartar o que vier como falha.** O pipeline já marca e descarta. O aluno nunca vê essa questão.
4. **Escolher o empacotamento.** Uma opção é usar o modelo base e o adaptador separados, como foi medido. A outra é um GGUF único com o adaptador mesclado, que exige passar pelo gate de novo.
5. **Manter o 1.7B como alternativa** para aparelhos com pouca memória.

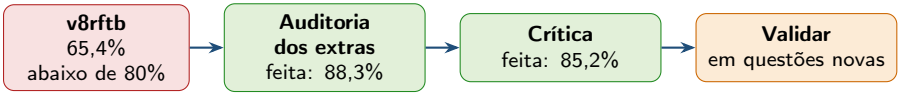
Pontos de atenção



Cerca de 790 questões geradas por modelo, nos mesmos 800 prompts. "Nenhuma das anteriores" é a presença da alternativa. O equilíbrio seria 20% por letra.

- ⚠ **O viés de letra persiste.** Balancear o treino levou o gabarito A de 44,1% para só 41,7%. O gate passou porque o v7b também deu 40% nas rodadas dele. Embaralhar as opções no app resolve isso.
- ⚠ **Nenhuma das anteriores** quase dobrou. Ela aparece em cerca de 23% do corpus, então o modelo está copiando o treino. Para o professor, não prejudicou (59% contra 68%, dentro do ruído).
- ⚠ **9º ano** continua como o ponto fraco: 54% no v7b e 50% no v8rftb.

Próximos passos



Ação	Motivo
Manter o v7b como referência e não publicar o v8rftb	Mesmo núcleo, sem adotar um modelo não confirmado
Validar gerar e criticar em uma folha nova do professor	A crítica foi desenhada olhando estas 78 questões. O IC ainda começa em 73%
Medir gerar e criticar em um celular real	São cerca de 105 s por questão entregue no PC. No celular é que se decide se cabe no app
Embaralhar as alternativas no app	Resolve o viés de letra para o aluno, independente do modelo
Próximo ciclo de dados: 9º ano com enunciados coerentes	É onde estão as reprovações, no modelo e na conferência
ORPO descartado por ora	Os dados já são bons e os pares vêm do mesmo filtro, então não atacam a causa

Apêndice: arquivos de evidência

Arquivo	Conteúdo
`ciclo_v8/SPEC.md`	Hipótese, decisões, auditoria e resultados do ciclo
`outputs/melhoria_v8/F/`	Folha do professor (222 itens) e apuração
`outputs/melhoria_v8/folha_v8rftb/`	Folha do professor (78 itens do v8rftb) e apuração
`outputs/melhoria_v8/auditoria_extras_rft/`	Auditoria cega dos extras (60 extras e 20 controles)
`outputs/melhoria_v8/auto_conferencia/`	Respostas e apurações de gerar e conferir
`src/auto_conferencia.py`	Conferência (modos direto, cot e crítica)
`outputs/melhoria_v8/validacao_jev_fora_da_amostra.json`	Calibração do Jev
`outputs/melhoria_v8/calibracao_maritaca.json`	Calibração da Maritaca
`data/train_curado_v8_rft_bal.jsonl`	Corpus treinado (3.793 questões)
`data/aval_{v7b,v8rftb}.jsonl`	800 amostras pareadas por modelo
`outputs/relatorios/VEREDITO_v8rftb_vs_v7b_multiseed.json`	Gate PROMOVIDO
`outputs/relatorios/VEREDITO_v8rftb_..._G1_todos_reprovado.json`	Veredito anterior à revisão do G1*
`outputs/qwen3_4b/lora_4b_v8rftb_s44.f16.gguf`	Adaptador do candidato (66 MB)
`outputs/qwen3_4b/Qwen3-4B-Q4_K_M.gguf`	Modelo base, gerador e resolvedor da conferência (2,5 GB)