R3. Reunião de acompanhamento

Ciclo v8 do Qwen3-4B: base de dados, juízes, gate e expectativa para o aplicativo

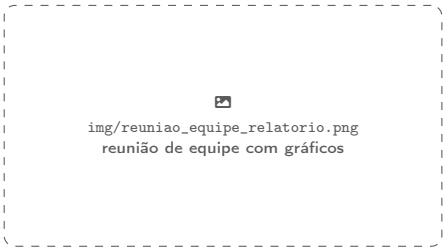
Relatório de execução de 19 a 23 de outubro de 2026

Qwen3-4B + QLoRA + GGUF, geração offline de questões SAEB de Matemática

23 de outubro de 2026

Roteiro

1. Resumo executivo
2. Ponto de partida: o que o professor mediu
3. Como decidimos o caminho
4. Melhorias na base de dados
5. Juízes automáticos calibrados
6. Resultados: juízes pareados e gate
7. Comparação com os modelos anteriores
8. Expectativa para o aplicativo
9. Riscos e próximos passos



Resumo executivo

Base

2.918 questões reordenadas para *resolver antes de escrever as alternativas*, mais 875 questões novas aprovadas por juiz. Total de 3.793, com gabarito em 20% por letra.

Juízes

Jev: 64,6% $\rightarrow$ **73,4%** de aceitação (800 pares, $p < 0{,}001$). Maritaca: 60,2% $\rightarrow$ 66,5% (400 pares, $p = 0{,}065$). Os dois apontam a mesma direção.

Gate

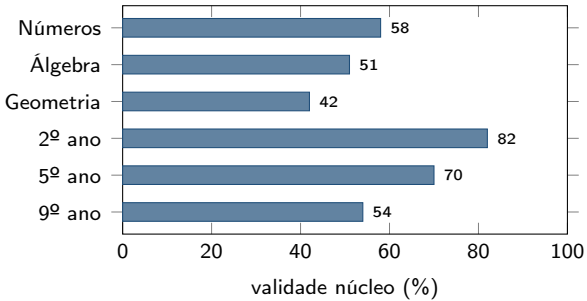
v8rftb contra v7b: **PROMOVIDO**. Consistência sobe de 93,6% para 100% e as falhas caem de 3 para 1 em 90.

O professor não confirmou o ganho: núcleo de **65,4%** (51 de 78, IC95 [54,3; 75,0]), contra 68,9% do v7b. A diferença está dentro do ruído e a meta de 80% não foi atingida. **Recomendação: não publicar o v8rftb.** O 9º ano e a Geometria seguem como pontos fracos.

Ponto de partida: 222 questões do 4B v7b avaliadas pelo professor

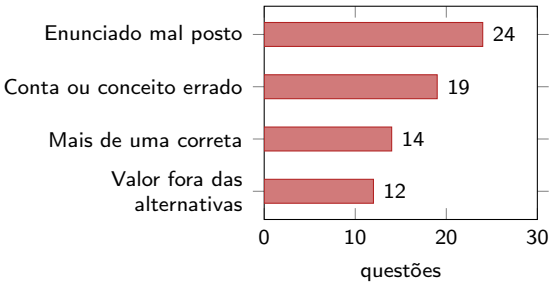
O professor avaliou às cegas 222 questões do melhor modelo da época (Qwen3-4B v7b). A questão é válida no critério **núcleo** quando a matemática está correta, só uma alternativa responde e os dados bastam.

- Núcleo: **68,9%**, IC95 [62,5; 74,6]
- A base de treino tem 97,9% de núcleo. O gargalo é o modelo, não os dados.
- Hiperparâmetros não mostraram efeito acima do ruído entre seeds.



9º ano e Geometria concentram as falhas.

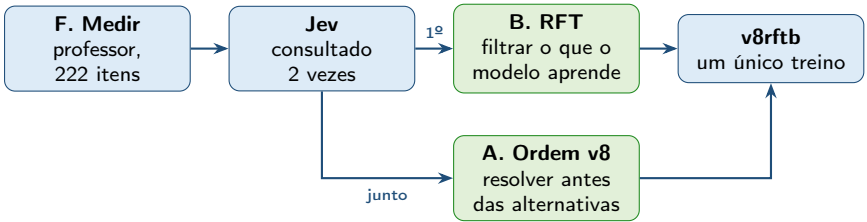
Por que as 69 questões falharam



A causa mais comum é o enunciado mal posto, com dados contraditórios ou inventados. Depois vêm a conta errada e a resposta duplicada.

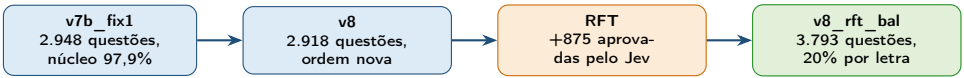
Reordenar o JSON resolve só a última barra, que vale cerca de **5 pontos**. Para as outras três, era preciso filtrar o que o modelo aprende. Daí veio o RFT (*Rejection Fine-Tuning*, ou ajuste fino por rejeição): o modelo gera várias questões, um juiz descarta as ruins e o modelo é treinado de novo só com as aprovadas.

Como decidimos o caminho



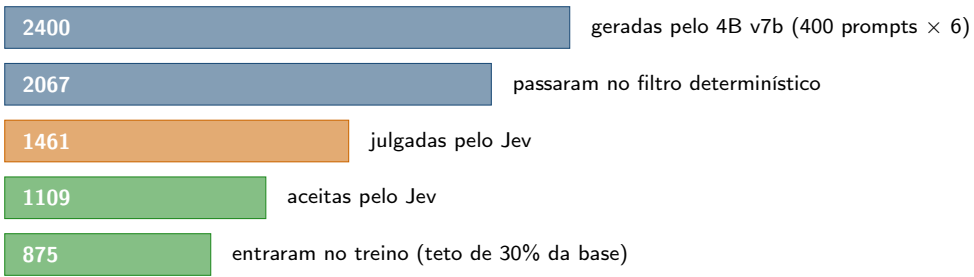
Consulta	Resultado
1ª, antes da medição	A primeiro (probabilidade média 0,76). A medição F era pré-requisito (0,94).
2ª, com a medição	B primeiro nas 4 ordens testadas (B 0,67 contra A 0,30). A e B se complementam.
Hiperparâmetros	Sem evidência de ganho acima do ruído entre seeds (0,05). Ficaram de fora.

Melhorias na base de dados



Mudança	Por que importa
Resolução antes das alternativas	O valor calculado já existe quando o modelo escreve as opções.
Uma questão por exemplo (47 divididos)	É o formato real do aplicativo, que pede uma questão por chamada.
Resolução sem citar "alternativa B"	As alternativas ainda não existem nessa ordem. Isso também permite embaralhar as opções no app.
Trava do verificador	Se a limpeza mudasse o veredito, a questão saía. Saíram 30 injetadas e nenhum item real do banco.
Extras com letras permutadas	Os extras chegaram com 34,5% de gabarito A. A permutação corrige para 20% cada.

RFT (ajuste fino por rejeição): o modelo gera, o juiz filtra, o modelo reaprende



- 606 amostras ficaram sem julgamento quando o crédito do OpenRouter acabou. Mesmo assim, as 79 habilidades receberam extras.
- Também saíram 282 pares bom/ruim, guardados para um treino ORPO futuro.

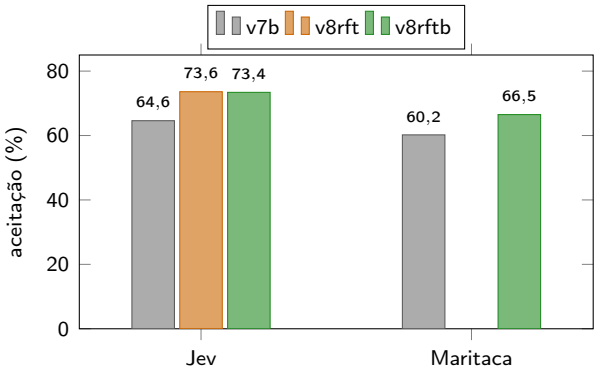
Dois juízes calibrados contra o professor

Antes de usar um juiz para decidir, conferimos se ele concorda com o professor nas mesmas 222 questões.

	Jev (TypeSafe)	**Maritaca** (sabiá-4)
Concordância com o professor (κ)	**0,795**	0,725
Inválidos que o juiz pega (recall)	81,2%	**90,9%**
Válidos que o juiz perde	**3,9%**	13,7%
Válidos entre os aceitos	91,9%	**95,7%**
Custo da calibração	US$ 0,01	R$ 5,36
Papel neste ciclo	filtro do RFT e 1º juiz	2º juiz, independente do filtro

A meta era $\kappa \geq 0{,}6$, e os dois passaram. A Maritaca é mais rígida e não participou do filtro de treino, então ela confirma o ganho sem viés de construção. Os dois rodam por API, por isso servem para medir e filtrar dados, mas não vão para o celular.

Resultados: os mesmos prompts e seeds nos dois modelos



Pareado	Jev	Maritaca
Pares	800	400
Só o v7b aceita	110	72
Só o v8rftb aceita	**180**	**97**
McNemar p	$< 0{,}001$	0,065

O balanceamento não custou qualidade, porque o v8rft e o v8rftb ficam empatados no Jev. No 9º ano, a aceitação do Jev sobe de 55% para 68%.

Gate mecânico: v8rftb contra v7b (3 rodadas, 90 pares)

Gate	O que verifica	v7b	v8rftb	
G1*	Estrutura do JSON nas questões entregues	100%	100% (n=89)	✅
G2*	Falhas depois das tentativas (teto 5%)	3/90	**1/90**	✅
G3*	Gabarito consistente com a conta	93,6%	**100%**	✅
G4	Dependência de figura	0	0	✅
G6*	Letra mais frequente (limite: base + 5 pontos)	40,0%	41,1%	✅
G7*	Sem esquecimento no 5º e 9º anos	100%	100%	✅
G5	Dificuldade (informativo)	100%	100%	✅
G8	Velocidade (informativo)	13,8 tok/s	15,0 tok/s	✅

Veredito: PROMOVIDO. O gate garante que nada piorou, mas não mede se a matemática está certa. Quem mede isso é o professor.

Mudanças nas regras do gate, com transparência

Data	Mudança e motivo	Tipo
22/10	G5 e G8 viram informativos e G9 sai. G5 só copiava o rótulo pedido (100% nos dois lados). G8 reprovou 6 de 18 vereditos por tamanho do modelo ou aquecimento da GPU.	Decisão do responsável, antes de medir o candidato
23/10	O G1* passa a contar só as questões entregues. O único item reprovado tinha B igual a D, mas já tinha sido descartado como falha e contado no G2*. Com 90 pares, o limite de 99% virava tolerância zero.	Revisão depois de uma reprovação, documentada no código

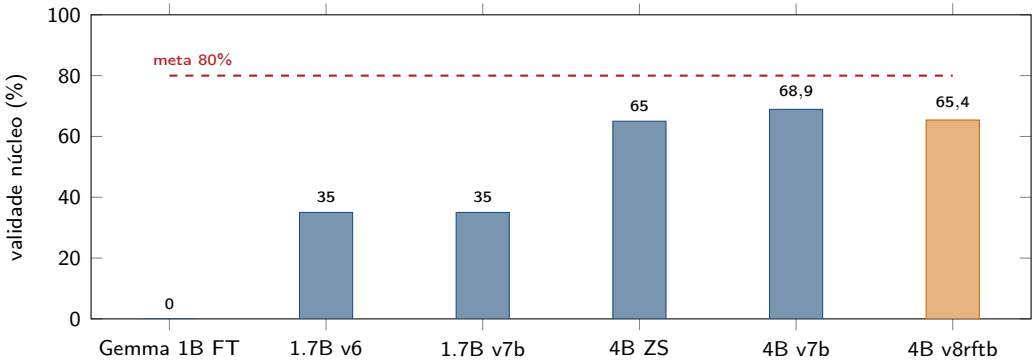
- Uma questão entregue com estrutura ruim continua reprovando. Três testes novos garantem isso.
- Com `-gates-completos`, a regra antiga volta e o veredito antigo (NÃO PROMOVIDO) se reproduz.
- O veredito reprovado ficou guardado como evidência.

Comparação com os modelos anteriores

Modelo	Tamanho	Núcleo (professor)	Gate	Melhor contribuição
Gemma 3 1B zero-shot	0,8 GB	15% (n=20)	base	Pipeline Gemma pronto e trava que impede comparar famílias diferentes
Gemma 3 1B fine-tune	0,8 GB	0% (n=20)	✗ 3 seeds	Mostrou que 1B não comporta a tarefa
Qwen3-1.7B v3	1,1 GB	50% (n=20)[a]	✓	Primeiro modelo publicado, gramática GBNF e gate multiseed
Qwen3-1.7B v6	1,1 GB	35% (n=20)	✓	Mostrou que passar no gate não garante qualidade, e a amostra humana passou a decidir
Qwen3-1.7B v7b	1,1 GB	35 a 50% (n=20)	✓	Base com 97,9% de núcleo, o que mostrou que o gargalo é o modelo
Qwen3-4B zero-shot	2,4 GB	65 a 70% (n=20)	base	Teste de teto: o tamanho do modelo pesa mais que a curadoria
Qwen3-4B v7b	2,5 GB	**68,9%** (n=222)	✓	Primeira medida confiável, taxonomia de falhas e calibração dos juízes
Qwen3-4B v8rftb	2,5 GB	65,4% (n=78)	✓	Gate e juízes melhoraram, mas o professor não viu ganho. Mostrou o limite do filtro por juiz de API

[a] Valor do baseline_v1 do 1.7B na amostra contra o v6. Com n=20, o intervalo de confiança tem cerca de ±20 pontos, por isso as linhas do 1.7B se sobrepõem. Tamanho do 4B fine-tunado: GGUF Q4_K_M de 2,4 GB mais adaptador LoRA de 66 MB.

A evolução em um gráfico

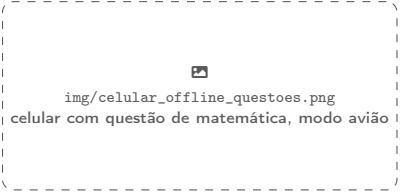


Todas as barras são medidas do professor (n=20 nos modelos pequenos, n=222 no 4B v7b e n=78 no v8rftb). O v8rftb (65,4%) e o v7b (68,9%) têm intervalos que se sobrepõem, e nenhum chega à meta de 80%.

Expectativa para o aplicativo mobile

Item	Qwen3-1.7B (hoje)	Qwen3-4B v8rftb
Arquivo do modelo	1,1 GB	2,4 GB + 66 MB
Memória estimada[b]	cerca de 1,4 GB	cerca de 3 GB
Velocidade (CPU do PC)	27 tok/s	15 tok/s
Tempo por questão (PC)	cerca de 8 s	cerca de 21 s
Núcleo (professor)	35 a 50%	65% (n=78)
Gramática enviada	`questao.gbnf`	`questao_v8.gbnf`

[b] Pesos mais o cache de 2.048 tokens (cerca de 0,3 GB no 4B). Estimativa de cálculo, ainda sem medida no aparelho.

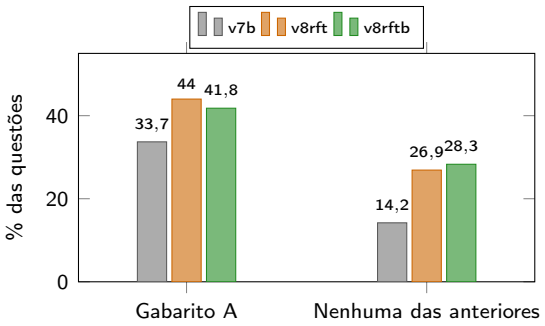


O que esperar: correção parecida com a do v7b (65 a 69%), bem acima do 1.7B, ao custo de cerca de 2,5 vezes mais tempo por questão e 2 vezes mais memória. Pela estimativa, o 4B pede aparelhos com 6 GB de RAM ou mais. Em celulares, a velocidade deve ficar abaixo da do PC. Por isso é preciso medir em um aparelho real antes de publicar.

O que muda na integração com o app

1. **Trocar a gramática junto com o modelo.** O v8 só funciona com `questao_v8.gbnf`, que o app envia inline. As chaves do JSON continuam as mesmas, então a leitura por nome de chave não muda.
2. **Embaralhar as alternativas no app.** A resolução do v8 não cita letras, então o app pode sortear a ordem das opções e remapear o gabarito. Assim o viés de letra deixa de importar para o aluno.
3. **Descartar o que vier como falha.** O pipeline já marca e descarta. O aluno nunca vê essa questão.
4. **Escolher o empacotamento.** Uma opção é usar o modelo base e o adaptador separados, como foi medido. A outra é um GGUF único com o adaptador mesclado, que exige passar pelo gate de novo.
5. **Manter o 1.7B como alternativa** para aparelhos com pouca memória.

Pontos de atenção



800 amostras pareadas por modelo. O equilíbrio seria 20% por letra.

- ⚠ **O viés de letra persiste.** Balancear o treino levou o gabarito A de 44,0% para só 41,8%. O gate passou porque o v7b também deu 40% nas rodadas dele. Embaralhar as opções no app resolve isso.
- ⚠ **Nenhuma das anteriores** dobrou. O corpus tem cerca de 21%, então o modelo está copiando o treino. O professor deve dizer se isso prejudica.
- ⚠ **9º ano e Geometria** continuam como os pontos fracos.

Resultado do professor e diagnóstico das 27 reprovadas

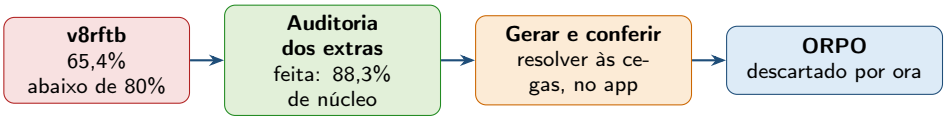
Recorte	Núcleo	n
Geral	**65,4%**	78
2º ano	83%	23
5º ano	59%	22
9º ano	50%	26
Geometria	46%	13
Grandezas e medidas	46%	13
Números	58%	33
Verificador `ok`	79%	42
Verificador não verificável	50%	36

Causas das 27 reprovadas, no texto do professor:

- cerca de 11 com enunciado contraditório (passageiros, troco, totais),
- cerca de 6 com mais de uma resposta correta,
- cerca de 4 com conta ou resolução errada e
- o restante com situação mal definida.

Nenhuma das anteriores não pesou (59% contra 68%, dentro do ruído). O filtro determinístico atual só marca o que não consegue verificar, então não separa bem.

Próximos passos



Ação	Motivo
Manter o v7b como referência	Mesmo núcleo do v8rftb, sem adotar um modelo não confirmado
Auditoria dos extras do RFT, já feita	Núcleo de 88,3% (n=60) contra 65,4% do modelo: os dados são bons e o gargalo é a geração
Validar a resposta na hora de gerar, dentro do app	Gerar, resolver de novo às cegas e aceitar só se concordar, sem API
Medir em um celular real e embaralhar as alternativas	Pendências do app, independentes do modelo
Descartar o ORPO por ora	Os dados já são bons e os pares vêm do mesmo filtro, então não atacam a causa

Apêndice: arquivos de evidência

Arquivo	Conteúdo
`ciclo_v8/SPEC.md`	Hipótese, decisões, auditoria e resultados do ciclo
`outputs/melhoria_v8/F/`	Folha do professor (222 itens) e apuração
`outputs/melhoria_v8/validacao_jev_fora_da_amostra.json`	Calibração do Jev
`outputs/melhoria_v8/calibracao_maritaca.json`	Calibração da Maritaca
`data/train_curado_v8_rft_bal.jsonl`	Corpus treinado (3.793 questões)
`data/aval_{v7b,v8rftb}.jsonl`	800 amostras pareadas por modelo
`outputs/relatorios/VEREDITO_v8rftb_vs_v7b_multiseed.json`	Gate PROMOVIDO
`outputs/relatorios/VEREDITO_v8rftb_..._G1_todos_reprovado.json`	Veredito anterior à revisão do G1*
`outputs/qwen3_4b/lora_4b_v8rftb_s44.f16.gguf`	Adaptador do candidato (66 MB)