

Ciclo de Treinamento L2-2026-09

Incorporação de 486 questões e retreino do gerador offline de questões de Matemática (SAEB)

Relatório técnico de execução

Pipeline QLoRA + GGUF — Qwen3-1.7B

16 de setembro de 2026

Sumário


- 1 Contexto e desenho experimental
- 2 Auditoria e incorporação do lote
- 3 Resultados de avaliação
- 4 Pontos positivos
- 5 Pontos negativos e riscos
- 6 Artefatos gerados
- 7 Recomendações

O que este ciclo fez

Ponto de partida. Um modelo Qwen3-1.7B já treinado (*baseline*), servindo questões de múltipla escolha de Matemática para um app mobile offline, cobrindo apenas os anos 2º, 5º e 9º.

O que chegou. Um lote de 499 questões autorais, cobrindo 1º, 2º, 3º e 4º ano — anos sem nenhuma cobertura anterior.


A pergunta do ciclo. Esse lote, depois de auditado e incorporado, melhora o modelo em produção o suficiente para justificar a troca?



Por que um modelo de controle foi necessário

O problema

O ambiente Python (venv) do ciclo anterior não existia mais, e o `requirements.txt` proíbe fixar versões de bibliotecas. O modelo novo teve de ser treinado com um *stack* diferente (torch 2.10, transformers 5.5, unsloth 2026.9.4). Comparar baseline contra candidato direto misturaria **duas variáveis**: os dados novos e a atualização de bibliotecas.




Toda comparação neste relatório usa o par **controle** × **candidato** (mesmo *stack*) ou **baseline** × **candidato** sob o mesmo pipeline, nunca baseline contra candidato de *stacks* distintos.

Auditoria do lote de 499 questões



96,4 % do lote



1,0 % do lote



2,6 % do lote

Gate mecânico do guia de entrega: 499/499 passaram — resultado atípico, tratado como suspeito até prova em contrário.

Evidências de autoria real (não geração automática):

- Cobertura do vocabulário do .docx de origem: **0,98**
- Duplicata exata com o banco / *leakage* / near-duplicata: **0** em todos

As 13 rejeições: um defeito, uma causa

Padrão único, todo em EF03MA01 (3º ano)

Pergunta de **identificação** respondida com uma **quantidade**, cuja justificativa é uma decomposição decorativa que não executa a comparação pedida.

Enunciado: “Na padaria, na segunda foram vendidos 597 pães e na sexta 842 pães.”

Pergunta: “**Em qual dia** foram vendidos menos pães?”

Gabarito: C = “597 pães.”

Justificativa: “Correto - $500 + 97 = 597$ ”

→ a conta *nunca compara* 597 com 842


Causa-raiz: a regra do guia (“a justificativa da correta traz a conta em números”) aplicada a uma habilidade **não-aritmética**. As 13 questões foram devolvidas ao autor — não corrigidas silenciosamente.

O banco de dados: antes, lote, depois

Métrica	Antes	Lote novo	Combinado
Linhas no banco	553	486	1.039
Questões que chegam ao treino de texto	303	476	779
Anos cobertos	2 ^o /5 ^o /9 ^o	1 ^o –4 ^o	1 ^o –5 ^o , 9 ^o
Habilidades distintas (ano×hab.)	55	10	65
Verificáveis por máquina	19,8 %	100 %	68,8 %
Gabarito D (mínimo histórico)	35	117	152

Das 486 incorporadas: **476** chegam ao treino de texto; **10** dependem de imagem e ficam só no banco. As 170 questões textualizadas que *têm* figura preservam o PNG (`imagem_path`) sem entrar no filtro que exclui do treino de texto — evitando repetir a perda histórica de 230 questões do banco original.

O ganho está localizado — e é real



Holdout de cobertura (30 itens, 1º–4º ano, fora do treino) — Teste de McNemar pareado:
ganhou 7, perdeu 0, $p = 0,016$

Onde não houve ganho — e por quê

Conjunto congelado (2º/5º/9º ano, n=30)

Mesmo conjunto do ciclo anterior, para comparação pareada e válida.

- Verificáveis: ganhou 1, perdeu 3
- McNemar: $p = 0,625$ ❌
- Estatisticamente é ruído

Esperado, não uma falha

O lote **não trouxe** nenhuma questão nova de 5º ou 9º ano (apenas reforçou 2º). Não haveria ganho a medir ali.

`eval_loss` — mesma configuração, único fator variado: os dados

Controle: 0,5583 → Candidato: **0,5362**
(−4,0 %)

Os 9 gates de promoção

Gate	Critério	Resultado	
G1	Estrutura $\geq 99\%$ e $\geq$ baseline	100 % em 7/7 flags	✓
G2	Falhas pós <i>best-of-N</i> = 0	0	✓
G3	Consistência $\geq$ baseline -5pp	100 % $\rightarrow$ 100 %	✓
G4	Dependência visual sem piora significativa	$p = 1,000$ (McNemar)	✓
G5	Aderência à dificuldade $\geq$ baseline -5pp	100 % $\rightarrow$ 100 %	✓
G6	Viés de gabarito $\leq$ baseline +5pp	46,7 % $\rightarrow$ 36,7 %	✓
G7	Sem esquecimento (5º/9º)	estrutura preservada	✓
G8	Velocidade $\geq$ baseline -10 %	26,3 $\rightarrow$ 26,5 tok/s	✓
G9	Perplexidade (<i>informativo</i>)	não medida	—

Decisão: PROMOVIDO (8/8 gates bloqueantes)


- ✓ **Ganho estatisticamente significativo** em cobertura de 1^o–4^o ano (McNemar $p = 0,016$), com destaque para 3^o ano (verificabilidade 4/9 $\rightarrow$ 9/9)
- ✓ **Verificabilidade do corpus real** praticamente triplicou: 19,8 % $\rightarrow$ 68,8 %
- ✓ **Zero *leakage*** entre o lote novo e o conjunto de validação, e zero contaminação entre treino/val/holdout
- ✓ **Nenhuma regressão estrutural** — 7/7 flags em 100 %, dificuldade e consistência preservadas, sem esquecimento de 5^o/9^o
- ✓ **Viés de gabarito reduzido** (46,7 % $\rightarrow$ 36,7 % na letra mais frequente)
- ✓ **Melhoria de produto**: filtro de dependência visual passou a regenerar questões que apontam para figura/gráfico inexistente
- ✓ **Rastreabilidade completa**: banco versionado com *backup*, *hash* sha256 de cada artefato, script de reversão documentado

O risco mais sério: erro matemático não detectado

Questão aceita com status não_verificável

“Em uma figura, o círculo tem raio 10 cm e a área da parte sombreada corresponde a 30 % da área do círculo. Qual o lado do triângulo inscrito?”

Resolução gerada: $a = \sqrt{376,8/\sqrt{3}} \approx 10\sqrt{3}$ cm ✖ correto $\approx 14,7$, não 17,3; o triângulo inscrito ocupa $\sim 41\%$ da área, não 30 %



■ Verificáveis
■ Sem checagem

No 9º ano, apenas **2 de 19** gerações são conferíveis pelo verificador determinístico.

Vale igualmente para o modelo anterior — não é regressão deste ciclo, é lacuna estrutural do produto.

Outros riscos abertos

-  Nunca testado em **hardware mobile real** — todas as métricas de velocidade são CPU de desktop (4 threads)
-  **Geração em lote** (quantidade > 1) não foi testada neste ciclo
-  $n = 30$ por conjunto: suficiente para o ganho de cobertura, insuficiente para estimar taxa de falha em produção
-  **Reprodutibilidade do *stack* perdida** — `requirements.txt` proíbe pinagem de versões
-  Histórico de `eval_loss` do baseline sobrescrito acidentalmente (suprido pelo modelo de controle)
-  Lote concentrado em **10 habilidades** (61 % do corpus real), risco de especialização excessiva

Honestidade do processo

Os gates **G4** (dependência visual) tiveram sua métrica e tolerância **revisadas depois de reprovarem** na primeira rodada — registrado explicitamente no código, com justificativa demonstrável sem depender do resultado (detector com falso positivo comprovado; tolerância de 2pp menor que a resolução do instrumento de medição, 3,3pp para $n = 30$).

Artefatos do ciclo — modelos e dados

Artefato	Descrição
gguf_gguf/*.gguf	Modelo promovido (candidato), quantizado Q4_K_M, 1,1 GB — artefato de produção
baseline_v1/*.gguf	Modelo anterior, preservado e reversível (<i>hash</i> sha256 registrado)
gguf_controle_gguf/*.gguf	Modelo de controle (dados antigos, <i>stack</i> novo) — isola o efeito do <i>stack</i>
lora/, lora_candidato/	Adaptadores LoRA do modelo promovido
questoes.db	Banco SQLite, 1.039 linhas (553 originais + 486 do lote)
questoes.antes-de-L2-*.db	<i>Backup</i> do banco anterior à incorporação
train.jsonl	Conjunto de treino, 963 exemplos (719 reais + 244 sintéticos)
val_frozen_v1.jsonl	Conjunto de validação congelado — idêntico ao ciclo anterior, garante comparação pareada
val_novos_v1.jsonl	<i>Holdout</i> de cobertura (30 itens, 1º–4º ano), fora do treino

Caminhos relativos a outputs/ (modelos) e DB/ / data/ (dados).

Artefatos do ciclo — código e relatórios

Artefato	Descrição
<code>validar_entrega.py</code>	Validador mecânico da entrega, referenciado pelo guia mas antes inexistente
<code>importar_entregas.py</code>	Incorporação versionada ao banco, com <i>backup</i> automático e rastreabilidade
<code>promover_checkpoint.py</code>	Aplica os 9 gates e emite o veredito de promoção de forma mecânica
<code>schema_utils.py</code> (revisado)	Acrescenta <code>DEPENDENCIA_VISUAL_PATTERN</code> , detector de referência dêitica
<code>test_model.py</code> (revisado)	<i>Best-of-N</i> passa a penalizar e regenerar dependência visual; seeds pareadas
<code>extract_data.py</code> (revisado)	Opção de conjunto de validação congelado e checagem de contaminação
<code>RELATORIO_CICLO*.md</code>	Relatório técnico completo do ciclo
<code>RELATORIO_QUALIDADE*.md</code>	Auditoria detalhada do lote de 499 questões
<code>VEREDITO_FINAL*.json</code>	Registro estruturado da decisão de promoção
<code>HF_MODEL_CARD.md</code>	<i>Model card</i> atualizado com os resultados deste ciclo

Caminhos relativos a `src/` (código) e `outputs/relatorios/` (relatórios); * = L2-2026-09.

- 1 **Testar o .gguf promovido em device real** antes de publicar no app — único teste que ainda não foi feito
- 2 **Fechar a lacuna de verificação do 9º ano** — maior risco aberto; um verificador simbólico (*sympy*) cobriria o que o regex `a op b = r` não alcança
- 3 **Corrigir a regra 1 do guia de entrega**, com exceção explícita para habilidades não-aritméticas
- 4 **Congelar** `requirements.lock` agora que o *stack* atual está validado
- 5 Devolver as 13 questões rejeitadas ao autor — são recuperáveis
- 6 Próximo lote: ampliar além de 10 habilidades, priorizando 5º/9º ano, onde este ciclo não trouxe ganho

Decisão final: PROMOVIDO

8/8 gates bloqueantes aprovados · ganho estatisticamente significativo em cobertura de 1^o–4^o ano ($p = 0,016$) · nenhuma regressão

Todos os números citados neste relatório são reproduzíveis a partir dos scripts e relatórios em `outputs/relatorios/`